

**CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA DE MINAS GERAIS
CAMPUS DIVINÓPOLIS**

Pablo Sousa da Silva

**AUTENTICAÇÃO BIOMÉTRICA NO CONTROLE DE ACESSO DO CEFET-MG:
MODERNIZAÇÃO TECNOLÓGICA EM RELAÇÃO AO CARTÃO NFC**

Divinópolis - MG

2026

PABLO SOUSA DA SILVA

**AUTENTICAÇÃO BIOMÉTRICA NO CONTROLE DE ACESSO DO CEFET-MG:
MODERNIZAÇÃO TECNOLÓGICA EM RELAÇÃO AO CARTÃO NFC**

Trabalho de Conclusão de Curso
apresentado no curso de Graduação em
Engenharia de Computação do Centro
Federal de Educação Tecnológica de Minas
Gerais como requisito parcial para obtenção
do título de Bacharel em Engenharia de
Computação.

Orientador: Prof. Me. Diego Ascânio Santos
Coorientador(a): Prof. Dra. Thabatta Moreira
Alves de Araújo

DIVINÓPOLIS - MG

2026

PABLO SOUSA DA SILVA

**AUTENTICAÇÃO BIOMÉTRICA NO CONTROLE DE ACESSO DO CEFET-MG:
MODERNIZAÇÃO TECNOLÓGICA EM RELAÇÃO AO CARTÃO NFC**

Trabalho de Conclusão de Curso
apresentado no curso de Graduação em
Engenharia de Computação do Centro
Federal de Educação Tecnológica de Minas
Gerais como requisito parcial para obtenção
do título de Bacharel em Engenharia de
Computação.

Aprovado em 29 de janeiro de 2026.

Título Nome

CEFET-MG Campus Divinópolis

Título Nome

CEFET-MG Campus Divinópolis

Título Nome

CEFET-MG Campus Divinópolis

Dedico aos meus pais e amigos que me auxiliaram durante o processo de construção deste trabalho.

AGRADECIMENTOS

Qual a diferença entre dedicatória e agradecimento?

A dedicatória na maioria das vezes é um texto curto, sucinto e bem objetivo que destaca a pessoa ou pessoas mais importantes na sua vida. Quando relacionada a vida pessoal, o autor deve agradecer a sua esposa, esposo, filhos, mãe, pai e avós.

No caso dos agradecimentos você não precisa se preocupar com o tamanho do texto. Você pode escrever um pouco mais sobre as pessoas que foram essenciais para seu sucesso. Nos agradecimentos, o autor pode falar da instituição, professores, coordenadores e amigos.

Exemplo: link

Agradeço primeiramente ao professor Msc. Dilson José Aguiar de Souza pela oportunidade de me orientar na conclusão deste trabalho e me ajudar na realização dos ensaios, além de me auxiliar com muita paciência.

Aos meus pais, Rubem Farias da Silva e Regina Cirinéia Menezes da Silva, por terem me dado força e sustentabilidade financeira no início do curso para chegar a esse momento. Aproveito também a oportunidade para agradecer todo o aporte que me deram em casa e o amor dedicado.

Aos meus irmãos Ana Paula Menezes da Silva e Alexandre Menezes da Silva pelas oportunidades de aprendizagem e troca de experiências.

À minha namorada Nicole Luise Fröhlich Kunsler pela dedicação oferecida, pelos momentos de companheirismo e pela compreensão aos momentos de ausência.

À empresa BLEISTAHL BRASIL METALURGIA S/A, em especial ao funcionário Manfred Kunrath, pela oportunidade de realizar o trabalho de conclusão com materiais fornecidos pela empresa, além de dar aporte financeiro para aquisição de materiais de apoio para a realização dos ensaios.

À empresa LESI Comércio e Representações LTDA, em especial a Fernando Mattes, representante na região da empresa SECO TOOLS que cedeu as ferramentas de corte para os ensaios.

Agradeço à UNISINOS pela cessão dos laboratórios da universidade e ao corpo de

funcionários da casa, principalmente aos que me deram apoio e auxílio quando possível e sempre que necessário.

“O ontem é história, o amanhã é um mistério, mas o hoje é uma dádiva. É por isso que se chama presente.”

Mestre Oogway

RESUMO

O resumo deve ressaltar o objetivo, o método, os resultados e as conclusões do documento. A ordem e a extensão destes itens dependem do tipo de resumo (informativo ou indicativo) e do tratamento que cada item recebe no documento original. Deve ser precedido da referência do documento, com exceção do resumo inserido no próprio documento, e ser composto de uma sequência de frases concisas, de cunho afirmativo e sem enumeração de tópicos, dado que se recomenda o uso de parágrafo único. As palavras-chave devem figurar logo abaixo do resumo, antecedidas da expressão palavras-chave, e finalizadas também por ponto. É importante evitar:

- a) símbolos e contrações que não sejam de uso corrente;
- b) fórmulas, equações, diagramas e similares que não sejam absolutamente necessários; quando seu emprego for imprescindível, deve-se defini-los na primeira vez em que aparecerem.

Quanto à extensão, os resumos devem ter:

- a) de 150 a 500 palavras os de trabalhos acadêmicos (teses, dissertações e outros) e relatórios técnico-científicos;
- b) de 100 a 250 palavras os de artigos de periódicos;
- c) de 50 a 100 palavras os destinados a indicações breves.

Como tratado, o resumo deve ser seguido das palavras representativas do conteúdo do trabalho, isto é, palavras-chave, ou descritores, no idioma em que foi redigido (mínimo 3). Elas devem ser separadas por ponto e vírgula e finalizadas com ponto final.

Palavras-chave: Palavra-chave 1; Palavra-chave 2; Palavra-chave 3; Palavra-chave 4; Palavra-chave 5.

ABSTRACT

Tradução do resumo em português.

Keywords: Keywords 1; Keywords 2; Keywords 3; Keywords 4; Keywords 5.

LISTA DE ILUSTRAÇÕES

Figura 1 – Pilha de Tecnologias utilizadas em Big Data	4
--	---

LISTA DE TABELAS

Tabela 1 – Comparação dos Frameworks 1

LISTA DE ABREVIATURAS E SIGLAS

LGPD	Lei Geral de Proteção de Dados Pessoais
NFC	Comunicação por Campo de Proximidade, do inglês Near Field Communication
GANs	Redes Generativas Adversariais, do inglês Generative Adversarial Networks
JSON	Notação de Objeto JavaScript, do inglês JavaScript Object Notation
FAR	Taxa de Falsa Aceitação, do inglês False Acceptance Rate
FRR	Taxa de Falsa Rejeição, do inglês False Rejection Rate

SUMÁRIO

1	INTRODUÇÃO	1
1.1	Figuras e Tabelas	1
1.2	Citação	1
1.2.1	Final do texto	1
1.2.2	Início do texto	2
1.3	Alíneas	2
1.4	Customização	3
1.5	Namedref	3
2	FUNDAMENTAÇÃO TEÓRICA	4
2.1	Seção	5
2.1.1	SubSeção	5
2.1.1.1	SubSubSeção	5
3	METODOLOGIA	6
3.1	Construção da base de dados sintética	6
3.2	Modelagem do cadastro de identidades	7
3.3	Extração inicial de características faciais (<i>baseline</i>)	8
3.4	Geração de variações sintéticas das imagens	9
3.5	Extração de <i>embeddings</i> faciais por modelo pré-treinado	10
3.6	Definição da métrica de similaridade	11
3.7	Protocolo experimental de avaliação	12
3.8	Procedimento de validação da viabilidade	13
4	RESULTADOS	14
5	CONCLUSÃO	15
	REFERÊNCIAS	16

1 INTRODUÇÃO

1.1 Figuras e Tabelas

Nos elementos flutuantes, as legendas devem estar alinhadas à esquerda com o comando **minipage**.

```
\begin{table}[!ht]
  \centering
  \begin{minipage}{0.7\textwidth}
    \caption{\label{tabela:ComparativoFrameworks}
      Comparação dos Frameworks}
    \resizebox{\textwidth}{!}{
      [...]
    }
    \caption*{\footnotesize Fonte: Elaborado pelo autor, 2023.}
  \end{minipage}
\end{table}
```

Tabela 1 – Comparação dos Frameworks

	MapReduce	Spark	Flink
Armazenamento	Disco	RAM	RAM
Granularidade	Grossa	Grossa	Fina
Estado	Sem	Sem	Com
Processamento	Lote	Micro lotes	Stream
Volume	Finito	Finito	Infinito
Linguagem.	Java	Scala	Java

Fonte: Elaborado pelo autor, 2023.

1.2 Citação

1.2.1 Final do texto

No atual cenário tecnológico, dados se tornaram um ativo de

alto valor \cite{gunther2017debating}.

No atual cenário tecnológico, dados se tornaram um ativo de alto valor (Günther *et al.*, 2017).

1.2.2 Início do texto

Segundo \textcite{gunther2017debating} Dados se tornaram um ativo de alto valor no atual cenário tecnológico.

Segundo Günther *et al.* (2017) Dados se tornaram um ativo de alto valor no atual cenário tecnológico.

1.3 Alíneas

Para criar alíneas utilize o comando `enumerate`, nunca `description` ou `itemize`. As alínea devem encerrar com um ponto e vírgula e a última deve encerrar com um ponto final.

```
\begin{enumerate}
  \item Primeiro item da alínea;
  \item Segundo item da alínea;
  \item Terceiro item da alínea.
\begin{enumerate}
  \item Primeiro item da subalínea;
  \item Segundo item da subalínea;
  \item Terceiro item da subalínea.
\end{enumerate}
\end{enumerate}
```

- a) Primeiro item da alínea;
- b) Segundo item da alínea;
- c) Terceiro item da alínea.
 - Primeiro item da subalínea;

- Segundo item da subalínea;
- Terceiro item da subalínea.

1.4 Customização

Esse pacote pode ser customizado passando argumentos da seguinte forma:

```
\usepackage[acronym, glossaries, index, labelref, debug]{CEFET}
```

- a) **acronym**: adiciona o suporte para lista de abreviaturas e siglas;
- b) **glossaries**: adiciona o suporte para glossário;
- c) **index**: adiciona o suporte para índice de assunto;
- d) **labelref**: `\ref{fig:1}` retorna Figura 1 em vez de 1 para todas as referências;
- e) **debug**: Ativa as réguas e os quadros para melhorar a visualização das medidas.

1.5 Namedref

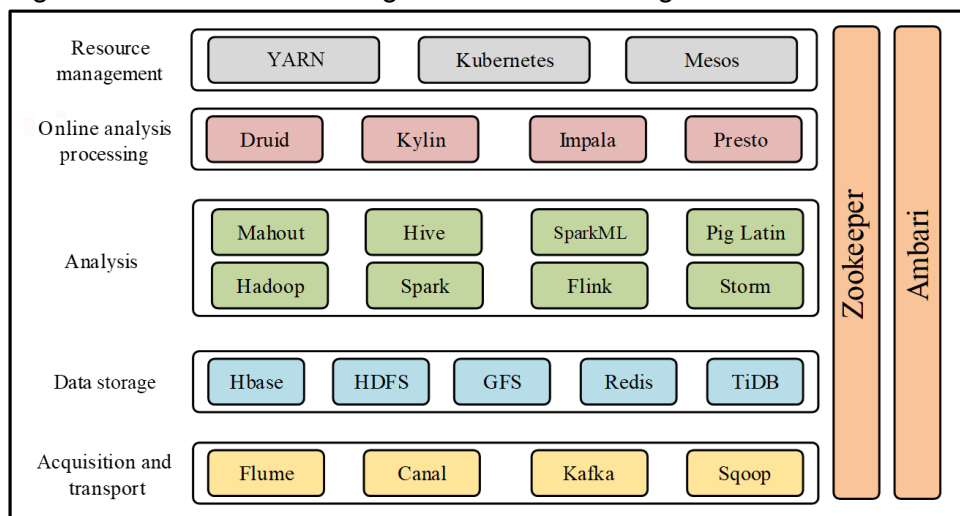
Exemplo de utilização do `\textbf{namedref}` para a
`\ref{tabela:ComparativoFrameworks}`.

Exemplo de utilização do **namedref** para a Tabela 1.

2 FUNDAMENTAÇÃO TEÓRICA

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum. Figura 1 (Anuradha *et al.*, 2015)

Figura 1 – Pilha de Tecnologias utilizadas em Big Data



Fonte: Sun *et al.* (2023).

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

2.1 Seção

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris. (Anuradha *et al.*, 2015)

2.1.1 SubSeção

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa. (Anuradha *et al.*, 2015)

2.1.1.1 SubSubSeção

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula. (Zaharia *et al.*, 2012)

3 METODOLOGIA

Este trabalho adota uma metodologia experimental com o objetivo de avaliar a viabilidade tecnológica do uso de reconhecimento facial como alternativa ao controle de acesso baseado em cartões NFC, no contexto acadêmico. A abordagem proposta fundamenta-se no conceito de aprendizado de representações em um espaço métrico, amplamente discutido na literatura de aprendizado profundo, em especial nas estratégias baseadas em redes siamesas e funções de perda do tipo *triplet loss*, conforme apresentado por Andrew Ng.

Nesse contexto, busca-se verificar se *embeddings* faciais extraídos por modelos de reconhecimento permitem a separação adequada entre diferentes identidades por meio de métricas de similaridade, possibilitando decisões confiáveis de autenticação e identificação. Considerando as restrições éticas e de privacidade associadas ao uso de dados biométricos reais, a metodologia emprega uma base de dados sintética e segue um conjunto estruturado de etapas, descritas a seguir, de forma a garantir reprodutibilidade e clareza na avaliação da abordagem proposta.

3.1 Construção da base de dados sintética

A construção da base de dados utilizada neste estudo teve como objetivo viabilizar a realização de experimentos de reconhecimento facial sem a utilização de dados biométricos reais, em conformidade com princípios éticos e com a Lei Geral de Proteção de Dados Pessoais (LGPD) (Lei nº 13.709/2018). Para esse fim, foi empregada uma base de imagens faciais sintéticas geradas artificialmente por meio de redes generativas adversariais (GANs), disponibilizadas publicamente pelo projeto *This Person Does Not Exist*, o qual produz imagens fotorrealistas de rostos inexistentes, disponível em (<https://thispersondoesnotexist.com/>).

Foram coletadas 400 imagens faciais sintéticas, cada uma representando uma identidade distinta. As imagens foram armazenadas em formato digital e organizadas em diretórios específicos do projeto, adotando-se um padrão de nomenclatura que permitisse a associação direta entre cada imagem e seu respectivo identificador de identidade. A utilização de dados sintéticos assegura que não exista qualquer vínculo com indivíduos

reais, eliminando riscos de identificação pessoal e atendendo às diretrizes de privacidade estabelecidas pela LGPD.

Com o objetivo de estruturar adequadamente os experimentos, a base de dados foi particionada em dois conjuntos principais: um conjunto de desenvolvimento, composto por 300 identidades, e um conjunto de teste final, composto por 100 identidades distintas. O conjunto de desenvolvimento foi subdividido em três subconjuntos: treino, validação e teste, contendo, respectivamente, 240, 30 e 30 identidades. Essa divisão visa permitir a avaliação controlada do comportamento do sistema em diferentes fases do processo experimental, além de evitar sobreposição de identidades entre os conjuntos.

Essa organização possibilita a realização de experimentos de reconhecimento facial de forma reprodutível e controlada, simulando um cenário de cadastramento e validação de usuários em sistemas de controle de acesso. A base de dados sintética construída nesta etapa constitui o insumo fundamental para as etapas subsequentes da metodologia, incluindo a extração de características faciais, a geração de *embeddings* e a avaliação da separabilidade entre identidades no espaço métrico.

3.2 Modelagem do cadastro de identidades

Após a construção e organização da base de dados sintética, procedeu-se à modelagem do cadastro de identidades a ser utilizado nos experimentos de reconhecimento facial. Essa modelagem teve como objetivo estruturar as informações de cada indivíduo de forma padronizada, facilitando o armazenamento, o processamento e a reprodutibilidade das etapas subsequentes da metodologia.

Cada identidade foi representada por um registro estruturado em formato JSON, contendo os seguintes atributos: um identificador único (*id*), um nome fictício, o nome do arquivo da imagem facial associada e um campo destinado ao armazenamento da representação vetorial da face (*embeddings*), inicialmente não preenchido. Essa estrutura permite a separação clara entre os dados descritivos da identidade e as informações extraídas automaticamente a partir das imagens faciais.

Com o intuito de organizar adequadamente os experimentos e evitar sobreposição de identidades entre diferentes fases de avaliação, o cadastro foi dividido em dois arquivos JSON distintos. O primeiro arquivo corresponde ao conjunto de desenvolvimento, contendo

as identidades destinadas às etapas de treino, validação e teste. Nesse arquivo, cada registro inclui um atributo adicional que indica a qual subconjunto a identidade pertence (train, validation ou test), respeitando a divisão previamente definida de 240, 30 e 30 identidades, respectivamente.

O segundo arquivo JSON foi destinado exclusivamente ao conjunto de teste final, composto por 100 identidades distintas e não presentes no conjunto de desenvolvimento. Esse conjunto tem como finalidade permitir uma avaliação independente da abordagem proposta, simulando um cenário em que o sistema é exposto a identidades não utilizadas nas fases anteriores do processo experimental.

A adoção de arquivos JSON distintos para o conjunto de desenvolvimento e para o teste final contribui para a organização do fluxo experimental, reduzindo riscos de vazamento de dados entre conjuntos e garantindo maior clareza na definição dos protocolos de avaliação. Além disso, o uso de um formato estruturado e amplamente suportado facilita a integração com os scripts de processamento, extração de *embeddings* e análise de similaridade empregados nas etapas subsequentes da metodologia.

3.3 Extração inicial de características faciais (*baseline*)

Como etapa inicial do estudo de viabilidade, foi implementada uma abordagem baseada na extração de características geométricas do rosto, utilizando o modelo MediaPipe FaceMesh, com o objetivo de validar o *pipeline* de processamento e estabelecer uma linha de base (*baseline*) para comparação com abordagens mais avançadas de reconhecimento facial. Essa etapa não tem como finalidade propor uma solução final, mas sim verificar a adequação do uso de representações vetoriais e métricas de similaridade no contexto do problema investigado.

Inicialmente, para cada imagem presente no conjunto de desenvolvimento, realizou-se a detecção automática da face por meio de um detector facial. Em seguida, a região facial detectada foi processada pelo modelo MediaPipe FaceMesh, o qual fornece um conjunto denso de pontos característicos (*landmarks*) distribuídos ao longo da face, cada um associado a coordenadas espaciais tridimensionais.

As coordenadas (x, y, z) correspondentes a cada *landmark* foram então concatenadas, formando um vetor numérico de dimensão fixa que representa a geometria

facial associada à imagem analisada. Esse vetor passou a ser utilizado como uma representação vetorial inicial da face, sendo armazenado no campo de *embedding* do cadastro de identidades em formato JSON.

A comparação entre diferentes faces foi realizada por meio da aplicação de uma métrica de similaridade entre os vetores gerados, permitindo o cálculo de distâncias entre pares de imagens. Essa abordagem possibilita observar o comportamento das distâncias para identidades iguais e distintas, servindo como referência experimental para a análise posterior de métodos baseados em aprendizado profundo e *embedding* treinados especificamente para reconhecimento facial.

3.4 Geração de variações sintéticas das imagens

Com o objetivo de aumentar a diversidade das amostras disponíveis para cada identidade e simular variações comuns no processo de captura de imagens faciais em ambientes reais, foi realizada a geração de variações sintéticas das imagens originais presentes no conjunto de desenvolvimento. Essa etapa visa tornar o processo de avaliação mais robusto frente a alterações de condições que podem ocorrer em cenários de controle de acesso, como mudanças de iluminação, pequenas variações de pose e degradações na qualidade da imagem.

Para cada imagem facial original associada a uma identidade, foram aplicadas transformações artificiais controladas, resultando na criação de múltiplas amostras derivadas da mesma identidade. As transformações empregadas incluem operações geométricas, como rotações leves e ajustes de escala, bem como transformações fotométricas, como variações de brilho, contraste e saturação. Adicionalmente, foram aplicadas técnicas de degradação da imagem, incluindo a inserção de ruído e a aplicação de filtros de desfoque, com o objetivo de simular condições adversas de captura.

As imagens geradas por meio desse processo foram armazenadas em um diretório específico, mantendo-se a associação com o identificador da identidade original. Para refletir essa ampliação do conjunto de dados, foi criado um novo arquivo JSON contendo múltiplos registros por identidade, cada um referenciando uma variação distinta da imagem facial, preservando-se o mesmo identificador único (id). Dessa forma, todas as variações de uma mesma identidade são tratadas como amostras positivas associadas a um único

indivíduo.

A geração dessas variações sintéticas é particularmente relevante no contexto de abordagens baseadas em aprendizado de representações em espaço métrico, nas quais se busca reduzir a distância entre diferentes amostras da mesma identidade e aumentar a separação em relação a amostras de identidades distintas. Embora nesta etapa não seja realizado treinamento de redes neurais, o conjunto de imagens gerado fornece subsídios adequados para avaliar o comportamento de *embeddings* faciais frente a variações de uma mesma identidade, conceito central em estratégias inspiradas em funções de perda do tipo *triplet loss*.

3.5 Extração de *embeddings* faciais por modelo pré-treinado

Após a geração das variações sintéticas das imagens faciais, procedeu-se à extração de *embeddings* faciais por meio de um modelo de reconhecimento facial pré-treinado baseado em aprendizado profundo. Essa etapa tem como objetivo representar cada face em um espaço vetorial no qual identidades iguais apresentem maior proximidade entre si, enquanto identidades distintas sejam mapeadas para regiões mais distantes, característica essencial para sistemas de reconhecimento facial baseados em métricas de similaridade.

Para essa finalidade, foi adotado um modelo amplamente utilizado na literatura e em aplicações práticas de reconhecimento facial, treinado previamente em grandes bases de dados de faces. O modelo empregado segue a filosofia de aprendizado de representações em espaço métrico, sendo treinado com funções de perda do tipo *margin-based*, conceitualmente relacionadas à *triplet loss*, cujo objetivo é maximizar a separação entre diferentes identidades e reduzir a distância entre amostras da mesma identidade.

Cada imagem presente no conjunto de dados ampliado foi processada individualmente pelo modelo, sendo inicialmente realizada a detecção da face e, em seguida, a extração do vetor de características correspondente. O *embedding* resultante consiste em um vetor numérico de dimensão fixa, capaz de capturar características discriminativas da face, de forma robusta a variações de iluminação, expressão facial e pequenas alterações de pose.

Os *embeddings* extraídos foram associados às respectivas identidades e armazenados no cadastro estruturado em formato JSON, substituindo o campo previamente reservado para a representação vetorial. Esse procedimento permitiu a construção de uma base de dados composta por múltiplas representações vetoriais por identidade, viabilizando a comparação entre amostras da mesma identidade e de identidades distintas nas etapas subsequentes da metodologia.

3.6 Definição da métrica de similaridade

Com os *embeddings* faciais extraídos e associados às respectivas identidades, definiu-se o método para quantificar a similaridade entre diferentes representações vetoriais. Essa etapa é fundamental em sistemas de reconhecimento facial baseados em aprendizado métrico, nos quais a decisão de correspondência entre identidades é realizada a partir da distância entre *embeddings* no espaço vetorial.

Neste trabalho, foi adotada a métrica de distância cosseno para a comparação entre pares de *embeddings* faciais. Essa métrica avalia o ângulo entre dois vetores, sendo amplamente utilizada em aplicações de reconhecimento facial por apresentar bom desempenho na comparação de vetores normalizados e por ser menos sensível à magnitude absoluta dos *embeddings*. A distância cosseno permite, assim, mensurar o grau de similaridade entre duas amostras faciais de forma consistente.

A partir da métrica de similaridade definida, estabeleceu-se um limiar de decisão (*threshold*) para determinar se dois *embeddings* correspondem à mesma identidade ou a identidades distintas. Distâncias inferiores ao limiar são interpretadas como correspondências positivas, enquanto distâncias superiores indicam não correspondência. A definição desse limiar é tratada como um parâmetro experimental, cuja adequação é avaliada por meio de análises quantitativas descritas nas etapas subsequentes da metodologia.

Esse procedimento reflete diretamente o princípio das abordagens inspiradas em redes siamesas e funções de perda do tipo triplet loss, nas quais o aprendizado visa estruturar o espaço de *embeddings* de modo que amostras da mesma identidade apresentem distâncias reduzidas, enquanto amostras de identidades diferentes sejam separadas por distâncias maiores, possibilitando decisões baseadas em métricas de

similaridade.

3.7 Protocolo experimental de avaliação

O protocolo experimental adotado neste trabalho tem como finalidade avaliar o comportamento das representações faciais no espaço de *embeddings* e verificar a capacidade da abordagem proposta em distinguir identidades distintas por meio de métricas de similaridade. Para isso, foram definidas estratégias de comparação entre amostras faciais, bem como métricas quantitativas para análise do desempenho do sistema, sem a realização de ajustes ou treinamentos adicionais dos modelos empregados.

As comparações foram organizadas a partir da definição de dois tipos de pares. Os pares genuínos correspondem a comparações entre amostras pertencentes à mesma identidade, incluindo imagens originais e variações sintéticas associadas a um mesmo identificador. Já os pares impostores correspondem a comparações entre amostras de identidades distintas. Essa distinção permite analisar o comportamento das distâncias de similaridade tanto em situações de correspondência legítima quanto em tentativas de correspondência indevida.

Para cada par de amostras, foi calculada a distância entre os *embeddings* faciais utilizando a métrica definida na etapa anterior. A partir dessas distâncias, avaliou-se o impacto de diferentes valores do limiar de decisão (*threshold*) na classificação das comparações como correspondências positivas ou negativas. Esse procedimento possibilita observar como variações no limiar influenciam o comportamento do sistema frente a pares genuínos e impostores.

Como métricas de avaliação, foram consideradas a taxa de falsa aceitação (*False Acceptance Rate* - FAR) e a taxa de falsa rejeição (*False Rejection Rate* - FRR). Essas métricas são amplamente utilizadas em sistemas biométricos e permitem caracterizar o compromisso entre segurança e usabilidade, aspecto fundamental em aplicações de controle de acesso. A análise conjunta dessas métricas fornece subsídios para a avaliação da separabilidade das identidades no espaço de *embeddings* e para a definição de critérios de viabilidade da abordagem estudada.

Esse protocolo experimental foi aplicado tanto à abordagem inicial baseada em

características geométricas quanto à abordagem baseada em *embeddings* extraídos por modelo pré-treinado, permitindo uma avaliação consistente do comportamento das diferentes representações faciais consideradas neste estudo.

3.8 Procedimento de validação da viabilidade

4 RESULTADOS

The typesetting markup language is specially suitable for documents that include

5 CONCLUSÃO

The typesetting markup language is specially suitable for documents that include

REFERÊNCIAS

ANURADHA, J *et al.* A brief introduction on Big Data 5Vs characteristics and Hadoop technology. **Procedia computer science**, Elsevier, v. 48, p. 319–324, 2015.

GÜNTHER, Wendy Arianne *et al.* Debating big data: A literature review on realizing value from big data. **The Journal of Strategic Information Systems**, Elsevier, v. 26, n. 3, p. 191–209, 2017.

SUN, Xudong *et al.* Survey of Distributed Computing Frameworks for Supporting Big Data Analysis. **Big Data Mining and Analytics**, TUP, v. 6, n. 2, p. 154–169, 2023.

ZAHARIA, Matei *et al.* Resilient distributed datasets: A fault-tolerant abstraction for in-memory cluster computing. *In*: 9TH {USENIX} SYMPOSIUM ON NETWORKED SYSTEMS DESIGN AND IMPLEMENTATION ({NSDI} 12). **Presented as part of the [...]** [S. l.: s. n.], 2012. p. 15–28.